

Repositorio del trabajo: <https://github.com/JOsorioCruz/estadisticas-y-analisis-de-datos>

Universidad de Cartagena

Programa	Ingeniería de Software
Asignatura	Probabilidad y Estadística
Código	AF17401
Título	Guía de actividad No 2: Estadística descriptiva
Autor	Jairo Alonso Osorio Cruz
Semestre	VI

Presentación

Este libro de Excel reúne el desarrollo de la Guía de actividad No 2 de Probabilidad y Estadística (AF17401), del programa de Ingeniería de Software de la Universidad de Cartagena. La guía plantea que la Gobernación del Tolima necesita conocer los índices de accidentalidad del departamento, sus posibles causas y sus puntos críticos, y para ello entrega una base con 400 accidentes de tránsito ocurridos en tres municipios.

Este trabajo desarrolla la fase inicial, que consiste en organizar los datos y describirlos. El libro contiene la Tabla 1 con seis conceptos estadísticos, el análisis de la velocidad registrada con su tabla de frecuencia, sus gráficos y sus medidas, y el análisis de la relación entre los años de experiencia del conductor y su histórico de infracciones mediante regresión lineal y correlación de Pearson. Las medidas se calcularon con fórmulas de Excel que apuntan a la hoja de datos incluida en los anexos.

Introducción

El crecimiento de las ciudades y del uso del vehículo automotor ha convertido los accidentes de tránsito en un problema de salud pública: dejan personas fallecidas y heridas, y pérdidas materiales considerables. Para formular soluciones, las autoridades encargadas de las vías y del tránsito necesitan información detallada sobre cuándo, dónde y bajo qué condiciones ocurren los siniestros.

La base de datos del Anexo 1 recoge 400 accidentes en Ibagué (185), Melgar (119) y Espinal (96). Cada registro tiene nueve variables: municipio, edad del conductor, personas fallecidas, personas heridas, velocidad registrada, costo del accidente, nivel educativo, años de experiencia e histórico de infracciones. Al revisarla encontramos 13 parejas de registros idénticos en todas sus columnas. Se conservaron los 400 registros para que el análisis corresponda a la base tal como fue entregada.

La estadística descriptiva resume un conjunto de datos con tablas, gráficos y medidas. Las medidas de tendencia central indican alrededor de qué valores se agrupan los datos, las de posición ubican valores dentro del orden de los datos, las de dispersión muestran qué tan separados están, y las de dependencia lineal miden si dos variables cambian juntas.

El libro sigue el orden de la guía. El ejercicio 1 define seis conceptos con ejemplos de la base, el ejercicio 2 analiza la velocidad registrada y el ejercicio 3 estudia la relación entre años de experiencia e infracciones. Después vienen las conclusiones, la bibliografía y los anexos, que incluyen la hoja de datos, la verificación de los cálculos y las convenciones que adoptamos.

Objetivos

Objetivo general

Emplear las medidas estadísticas de tendencia central, de dispersión, de posición y de dependencia lineal en la solución de problemas, aplicándolas a la base de datos de accidentalidad del Tolima.

Objetivos específicos

1. Explicar con palabras propias los conceptos de frecuencia absoluta, frecuencia relativa, media, medidas de dispersión, regresión lineal y correlación de Pearson, con ejemplos tomados de la base de datos.
2. Organizar la velocidad registrada en una tabla de frecuencia con datos agrupados, representarla con un histograma, un diagrama circular y un polígono de frecuencia, y calcular e interpretar sus medidas de tendencia central, de posición y de dispersión, su asimetría y su curtosis.
3. Establecer la relación lineal entre los años de experiencia del conductor y el histórico de infracciones mediante la ecuación de regresión, el coeficiente de determinación y el coeficiente de correlación de Pearson, y usar la ecuación para hacer predicciones.

Ejercicio 1: definiciones de conceptos estadísticos

Tabla 1. Definiciones de conceptos

Conceptos	Definiciones	Ejemplos
Frecuencia absoluta	Es la cantidad de veces que aparece un valor, o un grupo de valores, dentro de los datos. Se obtiene contando, así que siempre es un número entero, y si sumamos las frecuencias de todos los valores obtenemos el total de datos (n).	De los 400 accidentes de la base, 185 ocurrieron en Ibagué, 119 en Melgar y 96 en Espinal. Esos tres números son las frecuencias absolutas del municipio y suman 400.
Frecuencia relativa	Es la parte del total que representa cada valor. Se calcula dividiendo su frecuencia absoluta entre el total de datos y da un número entre 0 y 1, que también se puede escribir como porcentaje. Sirve para comparar grupos sin que importe cuántos datos tenga cada uno, y todas las frecuencias relativas juntas suman 1.	En Ibagué ocurrieron 185 de los 400 accidentes, es decir $185/400 = 0,4625$, o sea el 46,25%. Melgar aporta el 29,75% y Espinal el 24%. Por nivel educativo, los conductores bachilleres son $210/400 = 52,5\%$.
Media	Es el promedio de los datos: sumamos todos los valores y dividimos entre la cantidad de valores. Representa el punto de equilibrio de los datos, por eso un valor muy alejado del resto la mueve con facilidad. Solo se puede calcular con variables numéricas.	Al sumar las velocidades registradas de los 400 accidentes y dividir entre 400 resulta 89,86 km/h, es decir que en promedio el vehículo causante iba casi a 90 km/h. El costo medio por accidente es de 188,21 millones de pesos.
Medidas de dispersión	Indican qué tan juntos o qué tan repartidos están los datos alrededor de su centro. Dos conjuntos pueden tener la misma media y comportarse muy distinto: en uno los datos son parecidos entre sí y en otro están muy dispersos. Las más usadas son el rango (máximo menos mínimo), la varianza, la desviación típica y el coeficiente de variación, que es la desviación dividida entre la media y permite comparar variables con unidades diferentes.	Las velocidades van de 32,1 a 140,8 km/h, así que el rango es de 108,7 km/h. La desviación típica es de 30,39 km/h y el coeficiente de variación de 33,8%, lo que indica que las velocidades se alejan en promedio unos 30 km/h de la media. En cambio, los años de experiencia tienen media de 3,60 y desviación de 3,97, un coeficiente de variación de 110,2%, mucho más disperso en términos relativos.
Regresión lineal	Es una técnica que busca la recta que mejor describe cómo cambia una variable (la dependiente, y) cuando cambia otra (la independiente, x). La recta se escribe $y = a + bx$: la pendiente b dice cuánto cambia y por cada unidad que aumenta x, y el intercepto a es el valor de y cuando x vale 0. Se ajusta por mínimos cuadrados, de modo que las distancias de los puntos a la recta sean lo más pequeñas posible en conjunto. Sirve para predecir dentro del rango observado, pero por sí sola no demuestra que una variable cause la otra.	Con los años de experiencia (x) y el histórico de infracciones (y) de los 400 conductores, la recta es $y = 1,73 + 0,77x$. La pendiente indica que por cada año más de experiencia, el modelo asocia unas 0,77 infracciones adicionales en los últimos cinco años.
Correlación de Pearson	Es un número r, entre -1 y 1, que mide qué tan fuerte es la relación lineal entre dos variables numéricas y en qué sentido va. Si r se acerca a 1, cuando una variable sube la otra también; si se acerca a -1, cuando una sube la otra baja; y si está cerca de 0 no hay relación lineal, aunque podría existir otro tipo de relación. No depende de las unidades en que estén medidas las variables, y al elevarlo al cuadrado se obtiene el coeficiente de determinación.	Entre años de experiencia e infracciones, $r = 0,77$: relación positiva y fuerte. Entre velocidad y costo del accidente, $r = 0,04$: casi nula, es decir que en esta base ir más rápido no se asocia linealmente con un costo mayor.

Ejercicio 2: estadística descriptiva de la velocidad registrada

Variable elegida: velocidad registrada (km/h), variable cuantitativa continua (columna E de la hoja DATOS, 400 registros).

Tabla de frecuencia con datos agrupados: velocidad registrada (km/h)

Número de datos (n)	400
Valor mínimo	32.1
Valor máximo	140.8
Rango (R = máximo - mínimo)	108.7
Número de intervalos (k, regla de Sturges)	10
Amplitud teórica (R / k)	10.87
Amplitud adoptada (A), redondeada hacia arriba	11
Límite inferior del primer intervalo	32


Intervalo	Límite inferior (Li)	Límite superior (Ls)	Marca de clase (xi)	fi	Fi	hi	Hi	hi (%)	Hi (%)
[32 - 43)	32.0	43.0	37.5	34	34	0.0850	0.0850	8.50	8.50
[43 - 54)	43.0	54.0	48.5	40	74	0.1000	0.1850	10.00	18.50
[54 - 65)	54.0	65.0	59.5	18	92	0.0450	0.2300	4.50	23.00
[65 - 76)	65.0	76.0	70.5	38	130	0.0950	0.3250	9.50	32.50
[76 - 87)	76.0	87.0	81.5	40	170	0.1000	0.4250	10.00	42.50
[87 - 98)	87.0	98.0	92.5	50	220	0.1250	0.5500	12.50	55.00
[98 - 109)	98.0	109.0	103.5	48	268	0.1200	0.6700	12.00	67.00
[109 - 120)	109.0	120.0	114.5	62	330	0.1550	0.8250	15.50	82.50
[120 - 131)	120.0	131.0	125.5	34	364	0.0850	0.9100	8.50	91.00
[131 - 142]	131.0	142.0	136.5	36	400	0.0900	1.0000	9.00	100.00
Total				400		1.0000		100.00	

Los intervalos son cerrados a la izquierda y abiertos a la derecha, salvo el último, que incluye su límite superior.

Auxiliar del polígono (clases va


Marca xi	fi
26.5	0
37.5	34
48.5	40
59.5	18
70.5	38
81.5	40
92.5	50
103.5	48
114.5	62
125.5	34
136.5	36
147.5	0

Gráficos estadísticos y conclusiones




Conclusión del histograma

El intervalo con la barra más alta es [109 - 120] km/h, con 62 accidentes (15,5 %), y el de la barra más baja es [54 - 65] km/h, con solo 18 (4,5 %). Ese valle es un hueco entre dos intervalos vecinos que tienen 40 y 38 accidentes, así que la distribución no es simétrica ni tiene un único pico. Entre 87 y 120 km/h se concentran 160 accidentes (40,0 %), cuatro de cada diez. La base no trae el límite de velocidad de cada vía, por lo que esto muestra dónde se concentran los siniestros y no cuáles velocidades son excesivas.



Conclusión del diagrama circular

Cada porción es el porcentaje de accidentes de un intervalo de velocidad. La más grande es [109 - 120] con 15,5 % y la más pequeña es [54 - 65] con 4,5 %. Como ninguna porción pasa del 15,5 %, ninguna franja de velocidad domina sobre las demás. Los tres intervalos vecinos con más accidentes, de 87 a 120 km/h, suman el 40,0 %. Con diez porciones es difícil comparar tamaños a simple vista, por eso conviene apoyarse en el histograma.



Conclusión del polígono de frecuencia

El polígono une las marcas de clase y se cierra con dos intervalos vacíos, uno antes y otro después (marcas 26,5 y 147,5 km/h), por eso empieza y termina en 0. Arranca en 34 accidentes en la marca 37,5, cae a 18 en la marca 59,5 y desde ese valle sube, con una pequeña baja en 103,5, hasta el pico de 62 en 114,5 km/h. Después baja a 34 y 36. Como el punto medio del rango es 87 km/h y 230 accidentes (57,5 %) se registraron a esa velocidad o más, la distribución se inclina hacia las velocidades altas.

Preguntas con base en la tabla de frecuencia

1. ¿En cuál intervalo se observa la mayor cantidad de datos?

Intervalo de mayor frecuencia	[109 - 120)
Frecuencia absoluta máxima (fi)	62
Porcentaje de los accidentes (hi %)	15.50

El intervalo con más accidentes es [109 - 120) km/h, con 62 de los 400 registros (15,5 %). Es el intervalo modal de la tabla.

2. ¿Hasta cuál intervalo se acumula el 60 % de los datos?

Porcentaje acumulado buscado	60%
Intervalo donde se alcanza el 60 %	[98 - 109)
Hi (%) del intervalo anterior	55.00
Hi (%) del intervalo donde se alcanza	67.00
Estimación dentro del intervalo (km/h)	102.6

El 60 % se acumula en el intervalo [98 - 109) km/h. Hasta [87 - 98) el acumulado llega a 55,0 % (220 accidentes), todavía por debajo del 60 %, y al sumar los 48 accidentes de [98 - 109) pasa a 67,0 % (268 accidentes). Es decir que el 67 % de los accidentes ocurrió a menos de 109 km/h. Si suponemos que los datos se reparten de forma pareja dentro del intervalo, el 60 % se alcanza cerca de los 102,6 km/h.

Medidas de tendencia central y de posición de la velocidad registrada (km/h)

Medida	Resultado	Interpretación	Fórmula de Excel
Moda	81.60	La velocidad que más se repite en los accidentes es 81,6 km/h, con 5 registros. Al ser una variable continua este valor pesa poco: el intervalo más frecuente de la tabla es [109 - 120) km/h.	MODE.SNGL
Media	89.86	En promedio, el vehículo causante del accidente iba a 89,86 km/h.	AVERAGE
Mediana	94.05	La mitad de los accidentes ocurrió a 94,05 km/h o menos y la otra mitad a más de 94,05 km/h. Queda por encima de la media (89,86), lo que apunta a una ligera cola hacia las velocidades bajas.	MEDIAN
Mínimo	32.10	La velocidad más baja registrada en un accidente fue de 32,1 km/h.	MIN
Máximo	140.80	La velocidad más alta registrada en un accidente fue de 140,8 km/h.	MAX
Rango	108.70	Entre el accidente de menor velocidad y el de mayor velocidad hay 108,7 km/h de diferencia.	Máximo - Mínimo
Cuartil 1 (Q1)	66.25	El 25 % de los accidentes ocurrió a velocidades entre 32,1 y 66,25 km/h.	QUARTILE.INC(rango, 1)
Decil 5 (D5)	94.05	El decil 5 deja el 50 % de los accidentes a 94,05 km/h o menos, por eso coincide con la mediana.	PERCENTILE.INC(rango, 0.5)
Cuartil 3 (Q3)	114.85	El 75 % de los accidentes ocurrió a velocidades entre 32,1 y 114,85 km/h, y solo el 25 % superó los 114,85 km/h.	QUARTILE.INC(rango, 3)
Percentil 10 (P10)	44.03	El 10 % de los accidentes ocurrió a velocidades entre 32,1 y 44,03 km/h.	PERCENTILE.INC(rango, 0.1)
Percentil 80 (P80)	117.98	El 80 % de los accidentes ocurrió a 117,98 km/h o menos, y el 20 % restante superó esa velocidad.	PERCENTILE.INC(rango, 0.8)

Dispersión, asimetría y curtosis de la velocidad registrada (km/h)

Medida	Resultado	Interpretación	Fórmula de Excel
Varianza muestral	923.52	Es el promedio de los cuadrados de las distancias de cada velocidad a la media, y vale 923,52 (km/h) ² . Como está en unidades al cuadrado, se interpreta mejor con la desviación típica.	VAR.S
Desviación típica muestral	30.39	Las velocidades se desvían típicamente unos 30,39 km/h de la media de 89,86 km/h.	STDEV.S
Coefficiente de variación (%)	33.82	La desviación típica equivale al 33,82 % de la media. Es la medida que usamos para decidir si la distribución es homogénea.	Desviación típica / Media x 100
Asimetría	-0.2611	Es -0,26: negativa y de tamaño pequeño. La cola es un poco más larga hacia las velocidades bajas, en línea con que la mediana (94,05) quede por encima de la media (89,86).	SKEW
Curtosis (exceso)	-1.0033	Es -1,00, medida en exceso respecto a la distribución normal (que vale 0). Al ser negativa la distribución es platocúrtica, más aplanada que la normal.	KURT

Convención adoptada para interpretar

Usamos la varianza y la desviación típica muestrales (VAR.S y STDEV.S) porque los 400 registros se toman como una muestra de la accidentalidad del Tolima. Para clasificar usamos convenciones de uso común en estadística descriptiva, que no proceden de las lecturas del curso: homogénea si el CV es menor que 30 %, casi simétrica si el valor absoluto de la asimetría es menor que 0,5, y platocúrtica si la curtosis en exceso es negativa. SKEW y KURT son las versiones de muestra que calcula Excel.

Análisis de la distribución

¿La distribución es homogénea o heterogénea?

Es heterogénea. Con la convención adoptada (CV menor que 30 % es homogénea), el coeficiente de variación de 33,82 % la deja del lado heterogéneo, aunque cerca del límite. Las velocidades cambian de forma apreciable de un accidente a otro, y con otro umbral la etiqueta podría cambiar, por eso conviene dar el valor del CV junto con la conclusión.

¿Qué tipo de concentración presentan los datos?

La curtosis en exceso de -1,00 indica una distribución platocúrtica, es decir, con poca concentración de datos alrededor de la media. Las velocidades se extienden a lo largo del rango en vez de agruparse alrededor de un solo pico, algo que también se ve en el histograma: ningún intervalo pasa de 15,5 % de los accidentes.

¿Qué tipo de asimetría presentan los datos?

La asimetría de -0,26 es negativa. Con la convención adoptada (valor absoluto menor que 0,5 es casi simétrica), la distribución es casi simétrica, con una cola ligeramente más larga hacia las velocidades bajas. Esto coincide con que la media (89,86) sea algo menor que la mediana (94,05).


Regresión lineal: años de experiencia (x) e histórico de infracciones (y)

Variable independiente (x): años de experiencia del conductor. Variable dependiente (y): número de infracciones en los últimos cinco años.

Datos de partida	
Número de pares de datos (n)	400
Media de x (años de experiencia)	3.60
Media de y (infracciones)	4.51

Ecuación de regresión lineal (y = a + b x)			
Medida	Resultado	Interpretación	Fórmula de Excel
Pendiente (b)	0.7723	Por cada año más de experiencia, el modelo asocia unas 0,77 infracciones adicionales en los últimos cinco años. Esto describe una asociación y no demuestra que la experiencia cause las infracciones.	SLOPE(y, x)
Intercepto (a)	1.7278	Es el valor que da la recta para un conductor con 0 años de experiencia: 1,73 infracciones. Ojo: los 53 conductores con 0 años tuvieron en promedio 1,06, así que la recta se aleja algo de los datos en ese extremo.	INTERCEPT(y, x)
Ecuación de la recta	y = 1.7278 + 0.7723 x	Es la recta de mínimos cuadrados: con ella se estima el número de infracciones a partir de los años de experiencia.	"y = " & a & " + " & b & " x"
Tipo de relación según la pendiente	Positiva	Positiva. La pendiente es mayor que cero y la nube de puntos sube de izquierda a derecha: a más años de experiencia, tienden a ser más las infracciones acumuladas. La fuerza de esa relación se mide con el coeficiente de determinación y con r.	Signo de b
Promedio observado de y con x = 0	1.06	Se usa para comparar el intercepto de la recta con lo que ocurre realmente en los conductores sin experiencia.	AVERAGEIF(x, 0, y)

Diagrama de dispersión con la recta de regresión



Lectura del diagrama

Positiva. La pendiente es mayor que cero y la nube de puntos sube de izquierda a derecha: a más años de experiencia, tienden a ser más las infracciones acumuladas. La fuerza de esa relación se mide con el coeficiente de determinación y con r. Como las dos variables son números enteros, muchos conductores comparten la misma pareja de valores y sus puntos quedan uno encima de otro. Por eso se ven menos puntos que los 400 registros.

Patrón de los datos

Los datos no forman una nube pareja, sino tres tramos. Con 0 o 1 año de experiencia (118 conductores) las infracciones van de 0 a 2. Con 2 a 10 años (256) van de 2 a 8 y su promedio casi no cambia de un año a otro (entre 4,33 y 6,00). Con 11 años o más (26) van de 10 a 20. La recta resume ese escalón con una sola pendiente, así que sirve como aproximación general pero no describe bien cada tramo por separado.

Coeficiente de determinación, confiabilidad y correlación de Pearson

Medida	Resultado	Interpretación	Fórmula de Excel
Coeficiente de determinación (R²)	0.5966	La recta explica el 59,66 % de la variación del número de infracciones a partir de los años de experiencia. El 40,34 % restante depende de otros factores o de variación que la recta no recoge.	RSQ(y, x)
Confiabilidad del modelo (%)	59.66	Es el mismo R² expresado en porcentaje: 59,66 %. El modelo da una idea general de cuántas infracciones se esperan según la experiencia, pero deja sin explicar cerca del 40 % de la variación, así que sus predicciones son orientativas y no exactas.	R² x 100
Coeficiente de correlación de Pearson (r)	0.7724	Es 0,7724, un valor positivo: al aumentar los años de experiencia tienden a aumentar las infracciones. Elevado al cuadrado da 0,5966, que es el R².	CORREL(y, x)
Nivel de correlación lineal	Regular	Regular según la escala adoptada (r entre 0,50 y 0,80). Como r = 0,77 está cerca del límite de 0,80 que separaría 'aceptable', conviene citar el valor de r junto con la etiqueta.	IF anidado sobre r

Escala adoptada para el nivel de correlación (|r|)

Intervalo de r	Nivel
r = 1	Perfecta
0,90 a menos de 1	Excelente
0,80 a menos de 0,90	Aceptable
0,50 a menos de 0,80	Regular
Mayor que 0 y menor que 0,50	Mínima
r = 0	Sin correlación

Esta escala es una convención de uso común que adoptamos en este trabajo. No proviene de las lecturas del curso, y otras escalas usan límites distintos.

Cómo leer estos resultados

Estos valores resumen el ajuste global de la recta. El diagrama mostró tres tramos y, entre 2 y 10 años de experiencia, el promedio de infracciones casi no cambia (entre 4,33 y 6,00), así que un R² de 59,66 % no significa que las infracciones suban de forma continua con cada año. Además, una correlación, por alta que sea, no prueba que la experiencia cause las infracciones.

Predicciones con la ecuación de regresión

La ecuación es $y = a + b x$, con a y b tomados de las celdas de la pendiente y el intercepto. Las celdas amarillas se pueden cambiar.

Predicción	Experiencia x (años)	Infracciones estimadas $\hat{y}$	Promedio observado con ese x	Conductores con ese x	¿ x dentro del rango observado?	Interpretación
Predicción 1	1	2.50	0.51	65	Sí	Para un conductor con 1 año de experiencia, el modelo estima 2,50 infracciones en los últimos cinco años. Los 65 conductores con 1 año tuvieron en promedio 0,51; la estimación queda por encima de lo observado y la recta sobreestima en este tramo.
Predicción 2	5	5.59	5.38	16	Sí	Para un conductor con 5 años de experiencia, el modelo estima 5,59 infracciones en los últimos cinco años. Los 16 conductores con 5 años tuvieron en promedio 5,38; la estimación coincide bien con lo observado.
Predicción 3	12	11.00	15.50	8	Sí	Para un conductor con 12 años de experiencia, el modelo estima 11,00 infracciones en los últimos cinco años. Los 8 conductores con 12 años tuvieron en promedio 15,50; la estimación queda por debajo de lo observado y la recta subestima en este tramo.

Error típico de la estimación (STEYX)	2.52
---------------------------------------	------

Cómo usar las predicciones

Las tres predicciones usan valores dentro del rango observado (0 a 30 años), que es donde la ecuación puede usarse. El error típico de la estimación es de 2,52 infracciones, así que cada predicción debe leerse con un margen de ese orden. Por el patrón de tres tramos visto en el diagrama, la recta funciona mejor en el tramo intermedio (2 a 10 años) que en los extremos.

Conclusiones

Ejercicio 1

Las seis definiciones quedaron ilustradas con cifras de la base, lo que permitió ver cada concepto aplicado. Por ejemplo, 185 de los 400 accidentes ocurrieron en Ibagué, es decir el 46,25 %, y las velocidades tienen una desviación típica de 30,39 km/h alrededor de una media de 89,86 km/h.

Ejercicio 2

La velocidad registrada tiene una media de 89,86 km/h, una mediana de 94,05 km/h y valores entre 32,1 y 140,8 km/h. El intervalo con más accidentes es [109 - 120) km/h, con 62 registros (15,5 %), y el 60 % de los accidentes se acumula hasta el intervalo [98 - 109) km/h. La mitad central de los accidentes ocurrió entre 66,25 y 114,85 km/h, y el 20 % más rápido superó los 117,98 km/h. Con un coeficiente de variación de 33,82 % la distribución es heterogénea según la convención adoptada, y con una asimetría de -0,26 y una curtosis de -1,00 resulta casi simétrica y platicúrtica: las velocidades se extienden por todo el rango sin concentrarse alrededor de un valor.

Ejercicio 3

La recta de regresión entre los años de experiencia (x) y las infracciones (y) es $y = 1,7278 + 0,7723 x$, con una relación positiva. El coeficiente de determinación es 0,5966 (59,66 %) y el coeficiente de correlación de Pearson es 0,7724, un nivel regular de correlación lineal según la escala adoptada, cerca del límite con el nivel aceptable. El diagrama de dispersión muestra tres tramos de experiencia, por lo que la recta sirve como aproximación general: con 5 años estima 5,59 infracciones y el promedio observado es 5,38, pero con 12 años estima 11,00 frente a 15,50 observadas. El error típico de la estimación es de 2,52 infracciones, así que las predicciones son orientativas.

Conclusión general

En esta base la velocidad se reparte a lo largo de un rango amplio, con el 45 % de los accidentes a 98 km/h o más, y los conductores con más años de licencia tienden a acumular más infracciones. Estos resultados describen los datos y no explican causas: la base no trae el límite de velocidad de cada vía, y una correlación no prueba que una variable produzca la otra. Los umbrales de homogeneidad, asimetría y correlación son convenciones que adoptamos y se declaran donde se usan.

Bibliografía

Romero Ramos, E. (2016). *Estadística para todos: análisis de datos: estadística descriptiva, teoría de la probabilidad e inferencia*. Difusora Larousse - Ediciones Pirámide. <https://elibro.unicartagenaproxy.elogim.com/es/lc/unicartagena/titulos/49136>

Salazar Guerrero, L. J. (2018). *Probabilidad y estadística: para bachilleratos tecnológicos*. Grupo Editorial Patria. <https://elibro.unicartagenaproxy.elogim.com/es/lc/unicartagena/titulos/40531>

Anexos

Anexo A. Hoja de datos

Copia exacta, sin modificar ningún valor, de la hoja DATOS del Anexo 1: 400 registros y 9 columnas. Es la hoja a la que apuntan todas las fórmulas del libro.

La base contiene 13 parejas de registros idénticos en las nueve columnas. Están en las filas 213 y 313, 214 y 314, 220 y 320, 221 y 321, 227 y 327, 237 y 337, 240 y 340, 241 y 341, 246 y 346, 269 y 369, 285 y 385, 300 y 400, 301 y 401 de la hoja (numeración de Excel, con el encabezado en la fila 1). Cada pareja está separada exactamente por 100 filas. Se conservaron todos los registros.

Anexo B. Verificación de los cálculos

Se compararon 141 valores del libro con cálculos independientes hechos en Python (numpy y scipy) a partir de los datos originales, y con el recálculo de las fórmulas de Excel en LibreOffice. Todos coincidieron, con una diferencia absoluta máxima de $5,7 \times 10^{-13}$. La tabla lista cada comparación.

Las tablas, los gráficos y las fórmulas del libro se generaron con un programa en Python (biblioteca `xlswriter`) que escribe fórmulas nativas de Excel.

Ejercicio	Bloque	Medida	Valor en Excel (recalculado)	Valor en Python	Diferencia	Resultado
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 1: Li	32.000000	32.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 2: Li	43.000000	43.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 3: Li	54.000000	54.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 4: Li	65.000000	65.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 5: Li	76.000000	76.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 6: Li	87.000000	87.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 7: Li	98.000000	98.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 8: Li	109.000000	109.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 9: Li	120.000000	120.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 10: Li	131.000000	131.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 1: Ls	43.000000	43.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 2: Ls	54.000000	54.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 3: Ls	65.000000	65.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 4: Ls	76.000000	76.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 5: Ls	87.000000	87.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 6: Ls	98.000000	98.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 7: Ls	109.000000	109.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 8: Ls	120.000000	120.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 9: Ls	131.000000	131.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 10: Ls	142.000000	142.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 1: xi	37.500000	37.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 2: xi	48.500000	48.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 3: xi	59.500000	59.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 4: xi	70.500000	70.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 5: xi	81.500000	81.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 6: xi	92.500000	92.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 7: xi	103.500000	103.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 8: xi	114.500000	114.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 9: xi	125.500000	125.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 10: xi	136.500000	136.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 1: fi	34.000000	34.000000	0.0E+00	Coincide

Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 2: fi	40.000000	40.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 3: fi	18.000000	18.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 4: fi	38.000000	38.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 5: fi	40.000000	40.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 6: fi	50.000000	50.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 7: fi	48.000000	48.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 8: fi	62.000000	62.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 9: fi	34.000000	34.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 10: fi	36.000000	36.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 1: Fi	34.000000	34.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 2: Fi	74.000000	74.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 3: Fi	92.000000	92.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 4: Fi	130.000000	130.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 5: Fi	170.000000	170.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 6: Fi	220.000000	220.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 7: Fi	268.000000	268.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 8: Fi	330.000000	330.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 9: Fi	364.000000	364.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 10: Fi	400.000000	400.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 1: hi	0.085000	0.085000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 2: hi	0.100000	0.100000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 3: hi	0.045000	0.045000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 4: hi	0.095000	0.095000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 5: hi	0.100000	0.100000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 6: hi	0.125000	0.125000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 7: hi	0.120000	0.120000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 8: hi	0.155000	0.155000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 9: hi	0.085000	0.085000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 10: hi	0.090000	0.090000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 1: Hi	0.085000	0.085000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 2: Hi	0.185000	0.185000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 3: Hi	0.230000	0.230000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 4: Hi	0.325000	0.325000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 5: Hi	0.425000	0.425000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 6: Hi	0.550000	0.550000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 7: Hi	0.670000	0.670000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 8: Hi	0.825000	0.825000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 9: Hi	0.910000	0.910000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 10: Hi	1.000000	1.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 1: hi %	8.500000	8.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 2: hi %	10.000000	10.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 3: hi %	4.500000	4.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 4: hi %	9.500000	9.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 5: hi %	10.000000	10.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 6: hi %	12.500000	12.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 7: hi %	12.000000	12.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 8: hi %	15.500000	15.500000	0.0E+00	Coincide

Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 9: hi %	8.500000	8.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 10: hi %	9.000000	9.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 1: Hi %	8.500000	8.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 2: Hi %	18.500000	18.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 3: Hi %	23.000000	23.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 4: Hi %	32.500000	32.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 5: Hi %	42.500000	42.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 6: Hi %	55.000000	55.000000	7.1E-15	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 7: Hi %	67.000000	67.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 8: Hi %	82.500000	82.500000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 9: Hi %	91.000000	91.000000	0.0E+00	Coincide
Ejercicio 2	Tabla de frecuencia	Tabla, intervalo 10: Hi %	100.000000	100.000000	0.0E+00	Coincide
Ejercicio 2	Parámetros de la tabla	Parámetro n	400.000000	400.000000	0.0E+00	Coincide
Ejercicio 2	Parámetros de la tabla	Parámetro mín	32.100000	32.100000	0.0E+00	Coincide
Ejercicio 2	Parámetros de la tabla	Parámetro máx	140.800000	140.800000	0.0E+00	Coincide
Ejercicio 2	Parámetros de la tabla	Parámetro R	108.700000	108.700000	1.4E-14	Coincide
Ejercicio 2	Parámetros de la tabla	Parámetro k	10.000000	10.000000	0.0E+00	Coincide
Ejercicio 2	Parámetros de la tabla	Parámetro R/k	10.870000	10.870000	1.8E-15	Coincide
Ejercicio 2	Preguntas	Intervalo de mayor frecuencia	[109 - 120)	[109 - 120)	0.0E+00	Coincide
Ejercicio 2	Preguntas	Frecuencia absoluta máxima (fi)	62.000000	62.000000	0.0E+00	Coincide
Ejercicio 2	Preguntas	Porcentaje de los accidentes (hi %)	15.500000	15.500000	0.0E+00	Coincide
Ejercicio 2	Preguntas	Intervalo donde se alcanza el 60 %	[98 - 109)	[98 - 109)	0.0E+00	Coincide
Ejercicio 2	Preguntas	Hi (%) del intervalo anterior	55.000000	55.000000	7.1E-15	Coincide
Ejercicio 2	Preguntas	Hi (%) del intervalo donde se alcanza	67.000000	67.000000	0.0E+00	Coincide
Ejercicio 2	Preguntas	Estimación dentro del intervalo (km/h)	102.583333	102.583333	3.3E-13	Coincide
Ejercicio 2	Tendencia central y posición	Moda	81.600000	81.600000	0.0E+00	Coincide
Ejercicio 2	Tendencia central y posición	Media	89.861500	89.861500	1.4E-14	Coincide
Ejercicio 2	Tendencia central y posición	Mediana	94.050000	94.050000	0.0E+00	Coincide
Ejercicio 2	Tendencia central y posición	Mínimo	32.100000	32.100000	0.0E+00	Coincide
Ejercicio 2	Tendencia central y posición	Máximo	140.800000	140.800000	0.0E+00	Coincide
Ejercicio 2	Tendencia central y posición	Rango	108.700000	108.700000	1.4E-14	Coincide
Ejercicio 2	Tendencia central y posición	Cuartil 1 (Q1)	66.250000	66.250000	0.0E+00	Coincide
Ejercicio 2	Tendencia central y posición	Decil 5 (D5)	94.050000	94.050000	0.0E+00	Coincide
Ejercicio 2	Tendencia central y posición	Cuartil 3 (Q3)	114.850000	114.850000	0.0E+00	Coincide
Ejercicio 2	Tendencia central y posición	Percentil 10 (P10)	44.030000	44.030000	7.1E-15	Coincide
Ejercicio 2	Tendencia central y posición	Percentil 80 (P80)	117.980000	117.980000	1.4E-14	Coincide
Ejercicio 2	Dispersión, asimetría y curtosis	Varianza muestral	923.520068	923.520068	5.7E-13	Coincide
Ejercicio 2	Dispersión, asimetría y curtosis	Desviación típica muestral	30.389473	30.389473	1.8E-14	Coincide
Ejercicio 2	Dispersión, asimetría y curtosis	Coefficiente de variación (%)	33.818123	33.818123	5.0E-14	Coincide
Ejercicio 2	Dispersión, asimetría y curtosis	Asimetría	-0.261147	-0.261147	2.8E-16	Coincide
Ejercicio 2	Dispersión, asimetría y curtosis	Curtosis (exceso)	-1.003317	-1.003317	1.1E-15	Coincide
Ejercicio 3	Regresión lineal	Pendiente (b)	0.772304	0.772304	5.6E-16	Coincide
Ejercicio 3	Regresión lineal	Intercepto (a)	1.727776	1.727776	2.9E-15	Coincide
Ejercicio 3	Regresión lineal	Ecuación	y = 1.7278 + 0.7723 x	y = 1.7278 + 0.7723 x	0.0E+00	Coincide
Ejercicio 3	Regresión lineal	Tipo de relación	Positiva	Positiva	0.0E+00	Coincide
Ejercicio 3	Regresión lineal	Promedio con x = 0	1.056604	1.056604	4.4E-15	Coincide
Ejercicio 3	R ² , r y nivel	Coefficiente de determinación (R ²)	0.596628	0.596628	1.1E-16	Coincide

Ejercicio 3	R ² , r y nivel	Confiabilidad del modelo (%)	59.662754	59.662754	1.4E-14	Coincide
Ejercicio 3	R ² , r y nivel	Coefficiente de correlación de Pearson (r)	0.772417	0.772417	4.4E-16	Coincide
Ejercicio 3	R ² , r y nivel	Nivel de correlación lineal	Regular	Regular	0.0E+00	Coincide
Ejercicio 3	Predicciones	Predicción 1: $\hat{y}$	2.500079	2.500079	2.2E-15	Coincide
Ejercicio 3	Predicciones	Predicción 1: promedio observado	0.507692	0.507692	3.3E-16	Coincide
Ejercicio 3	Predicciones	Predicción 1: conductores	65.000000	65.000000	0.0E+00	Coincide
Ejercicio 3	Predicciones	Predicción 1: dentro del rango	Sí	Sí	0.0E+00	Coincide
Ejercicio 3	Predicciones	Predicción 2: $\hat{y}$	5.589295	5.589295	0.0E+00	Coincide
Ejercicio 3	Predicciones	Predicción 2: promedio observado	5.375000	5.375000	0.0E+00	Coincide
Ejercicio 3	Predicciones	Predicción 2: conductores	16.000000	16.000000	0.0E+00	Coincide
Ejercicio 3	Predicciones	Predicción 2: dentro del rango	Sí	Sí	0.0E+00	Coincide
Ejercicio 3	Predicciones	Predicción 3: $\hat{y}$	10.995421	10.995421	4.6E-14	Coincide
Ejercicio 3	Predicciones	Predicción 3: promedio observado	15.500000	15.500000	0.0E+00	Coincide
Ejercicio 3	Predicciones	Predicción 3: conductores	8.000000	8.000000	0.0E+00	Coincide
Ejercicio 3	Predicciones	Predicción 3: dentro del rango	Sí	Sí	0.0E+00	Coincide
Ejercicio 3	Predicciones	Error típico de la estimación	2.524047	2.524047	8.9E-16	Coincide

Anexo C. Variables elegidas en el foro

Nombre	Variable del ejercicio 2	Variables del ejercicio 3
Jairo Alonso Osorio Cruz	Velocidad registrada	Años de experiencia del conductor (x) e histórico de infracciones (y)

Anexo D. Convenciones adoptadas

Estas convenciones son de uso común en estadística descriptiva y no proceden de las lecturas del curso.

Varianza y desviación típica muestrales (VAR.S y STDEV.S), porque los 400 registros se toman como una muestra de la accidentalidad del Tolima.

Homogeneidad: la distribución es homogénea si el coeficiente de variación es menor que 30 % y heterogénea en caso contrario.

Asimetría: casi simétrica si su valor absoluto es menor que 0,5. Curtosis: platocúrtica si el exceso de curtosis es negativo.

Nivel de correlación según $|r|$: perfecta si vale 1, excelente de 0,90 a menos de 1, aceptable de 0,80 a menos de 0,90, regular de 0,50 a menos de 0,80, mínima por debajo de 0,50 y sin correlación si vale 0.